



UFC

AV2 – NLP

Comparação de Abordagens de NLP e LLMs para Classificação de Sentimentos e RAG

Marilia de Oliveira • 2026 • Campus Jardins de Anita

Agenda

Navegaremos pelos seguintes tópicos essenciais para entender a análise comparativa:

01. Dados e Baseline

- Dataset Buscapé
- Modelo TF-IDF + LogReg

02. Modelos LLM

- Zero-shot (XLM-R)
- Fine-tuning (BERTimbau)

03. Pipeline RAG

- Recuperação + Geração
- Avaliação Hit@K

04. Conclusões

Síntese dos aprendizados e comparações.

05. Próximos Passos

Melhorias futuras e novos experimentos.

Dataset: Buscapé

Antes de aplicar os modelos, é fundamental compreender a estrutura e as características dos dados.

73.627

Amostras Finais
(de 84.991 originais)

Estrutura dos Dados

review_text: Texto original da avaliação do usuário.

polarity: Rótulo binário (0 = negativo, 1 = positivo).

Desbalanceamento de Classes



O forte desbalanceamento impacta diretamente a interpretação das métricas, favorecendo a acurácia na classe majoritária.

Divisão dos dados

O particionamento adequado dos dados é crucial para uma avaliação justa e robusta.

80%

Treino

58.901 amostras

20%

Teste

14.726 amostras

Implicações na Avaliação

Devido ao desbalanceamento, métricas como Precision e Recall tornam-se essenciais. Modelos podem alcançar alta acurácia apenas prevendo a classe majoritária, mascarando falhas na classe negativa.

Questão 1: Visão geral

Comparativo de abordagens para classificação de sentimentos em avaliações de produtos.



Baseline

TF-IDF +

Regressão Logística

Abordagem clássica supervisionada



LLM Zero-shot

XLNet-RoBERTa

Sem treino prévio no dataset



BERTimbau

Fine-tuning

Modelo PT-BR ajustado

Pipeline da Questão 1

Fluxo de processamento desde a preparação dos dados até a avaliação final.



Modelo Baseline

Para estabelecer uma linha de base, foi utilizada uma abordagem estatística clássica.

TF-IDF
+
Regressão Logística

Características Principais:

- Supervisionado (treinado com dados rotulados)
- Computacionalmente leve e rápido
- Altamente eficaz para identificar a classe majoritária

Resultados do Baseline

Desempenho global elevado, mas com viés significativo.

0,949

Accuracy

0,806

F1-score Macro

Observou-se um **Recall baixo na classe negativa**. O modelo favorece a classe positiva dominante, inflando a acurácia enquanto falha em detectar críticas.

LLM Zero-shot (XLM-R)

Uma abordagem sem treinamento prévio no domínio específico.

XLM-RoBERTa

Modelo Multilíngue Pré-treinado



Modo Zero-shot

- Sem treino no Buscapé
- Uso direto do conhecimento prévio
- Generalização semântica

Resultados do LLM

Menor acurácia global, mas ganhos estratégicos na compreensão semântica.

0,847

Accuracy

Recall superior na classe negativa

Vantagens Qualitativas

O modelo demonstrou superioridade em interpretar:

- **Textos complexos e longos**
- **Ironia e sarcasmo**
- **Críticas implícitas**


Casos onde o baseline estatístico falha por depender de palavras-chave isoladas.

Comparação: Baseline vs LLM

Métrica	Baseline	LLM Zero-shot
Accuracy	0.949	0.847
Precision (macro)	0.938	0.666
Recall (macro)	0.742	0.828
F1 (macro)	0.806	0.701

Erros Complementares:

- Baseline erra / LLM acerta: 439 casos (Sutileza)
- LLM erra / Baseline acerta: 1.945 casos (Texto curto)
- Ambos erram: 312 casos (Ambiguidade)



Análise qualitativa

Examinando os casos de divergência para entender as forças de cada modelo.

Vitória do LLM

(439 casos)

- Textos longos
- Estrutura mista
- Ironia e sarcasmo
- Críticas implícitas

Vitória do Baseline

(1.945 casos)

- Textos muito curtos
- Avaliações genéricas
- Pouco contexto semântico

Falha Mútua

(312 casos)

- Ambiguidade severa
- Inconsistência texto-nota
- Difícil até para humanos

BERTimbau (fine-tuning)

O poder do estado da arte ajustado para o português e para o domínio.

BERTimbau

bert-base-portuguese-cased
Pré-treinado em PT-BR
(Domínio da Língua)

+

Fine-tuning

Supervisionado
Amostra Balanceada
10.000 avaliações (5k/5k)

Resultados do BERTimbau

Equilíbrio notável entre as classes positiva e negativa.

0,874

Accuracy

0,87

F1 Macro

Classe	Precision	Recall	F1
Negativa (0)	0,91	0,83	0,87
Positiva (1)	0,84	0,92	0,88

O ajuste fino em dados balanceados eliminou o viés visto no baseline. O BERTimbau alcançou F1-scores quase idênticos para ambas as classes, provando ser o modelo mais robusto e justo do experimento.

Questão 2: RAG (overview)

Retrieval-Augmented Generation: conectando dados externos à geração de texto.



Arquivo 1: POP

Procedimento Operacional de
Eletroposto
(Técnico / Processo)



Arquivo 2: LGPD

Política de Dados e Telemetria
(Compliance / Legal)



Arquivo 3: FAQ

Conceitos de NLP e Métricas
(Conceitual / Educativo)

Pipeline RAG

Fluxo de recuperação e geração de respostas contextualizadas.




Técnicas usadas no RAG

Retriever

TF-IDF + similaridade do cosseno
entre o vetor da pergunta e o vetor de
cada chunk

Generator

FLAN-T5-base
(resposta restrita ao contexto recuperado)



Avaliação RAG (Hit@K)

A métrica Hit@K mede se o trecho correto foi recuperado entre os K primeiros resultados, avaliando a eficiência do mecanismo de busca do RAG antes da etapa de geração.

1

Hit@1

1

Hit@2

1

Hit@3

Para todas as consultas testadas, o trecho relevante foi retornado corretamente nas primeiras posições, garantindo contexto preciso para o gerador.

Conclusões

Síntese dos principais aprendizados desta análise comparativa.

Os experimentos demonstraram que **modelos estatísticos (Baseline)** ainda dominam em métricas globais para tarefas simples, mas os **LLMs** oferecem ganhos insubstituíveis na compreensão de nuances e ironias. O ajuste fino do **BERTimbau** provou ser a estratégia mais equilibrada, eliminando o viés de classe. Por fim, a implementação do **RAG** validou a eficácia da recuperação híbrida para bases de conhecimento controladas.

Próximos passos

Direções futuras para aprofundar a pesquisa e aprimorar os modelos.

- **Ampliar Fine-tuning**
- **Explorar Ensemble (Híbridos)**
- **Embeddings Densos no RAG**
- **Testar Novos Datasets**
- **Análise Multiclasse / Aspectos**

Obrigada!