

TECHNICAL REPORT

Aluno: Francisca Marília de Oliveira Rodrigues
--

1. Introdução

Neste trabalho foi realizada uma análise comparativa de diferentes abordagens de Processamento de Linguagem Natural (NLP) aplicadas à tarefa de classificação de sentimentos em avaliações textuais de produtos. Inicialmente, foi implementado um modelo supervisionado clássico baseado em TF-IDF e Regressão Logística, utilizado como baseline na AV1. Em seguida, foram avaliados modelos baseados em Large Language Models (LLMs), tanto em modo zero-shot quanto por meio de modelos pré-treinados para a língua portuguesa ajustados supervisionadamente, com o objetivo de comparar desempenho quantitativo e qualitativo.

Adicionalmente, o trabalho contemplou a implementação de um pipeline de Retrieval-Augmented Generation (RAG), combinando técnicas de recuperação de informação e geração de texto, com o propósito de avaliar a capacidade do sistema em recuperar trechos relevantes e gerar respostas coerentes a partir de uma base documental. Os resultados obtidos foram analisados sob diferentes métricas e perspectivas, conforme solicitado na descrição da AV2.

Descrição do Dataset

Assim como na AV1, o dataset utilizado foi o **Corpus Buscapé**, composto por 84.991 registros contendo avaliações textuais de produtos acompanhadas de metadados e rótulos associados. Após as etapas de limpeza e pré-processamento, o conjunto final utilizado na tarefa de classificação passou a conter 73.627 amostras, organizadas em duas colunas principais:

- **review_text**: texto original da avaliação do usuário;
- **polarity**: rótulo binário de sentimento, em que
 - 1 representa sentimento positivo;
 - 0 representa sentimento negativo.

Uma característica relevante do dataset é o forte desbalanceamento entre as classes, com aproximadamente 90,7% de avaliações positivas e 9,3% negativas. Esse aspecto é fundamental para a correta interpretação das métricas de desempenho,

especialmente *precision*, *recall* e *F1-score* por classe, uma vez que modelos podem apresentar alta acurácia global mesmo com baixo desempenho na classe minoritária.

O conjunto de dados foi dividido em 80% para treinamento e 20% para teste, resultando em 58.901 amostras para treino e 14.726 para avaliação.

2. Observações

Durante o desenvolvimento da atividade, ocorreram desafios técnicos relacionados à compatibilidade entre versões de bibliotecas, especialmente envolvendo **NumPy**, **Transformers**, **datasets** e **PyTorch**, em função de atualizações recentes do ecossistema Python, pois no decorrer do trabalho avalei duas LLMs e as duas precisavam de versões específicas para que funcionassem corretamente. Esses problemas exigiram ajustes no ambiente computacional até que fosse possível executar corretamente os modelos baseados em LLM.

Apesar desses imprevistos, todos os experimentos planejados foram executados com sucesso, não havendo impacto nos resultados finais nem na validação das análises apresentadas.

3. Resultados e discussão

Questão 1 – Comparação entre Baseline e LLMs

Fluxo Geral da Questão

O fluxo de processamento adotado nesta questão pode ser resumido nas seguintes etapas:

1. Limpeza e seleção das colunas de texto e rótulo;
 2. Divisão do conjunto em treino e teste;
 3. Treinamento e avaliação do modelo baseline (TF-IDF + Regressão Logística);
 4. Aplicação de modelos LLM para classificação de sentimentos em modo zero-shot;
 5. Avaliação quantitativa e qualitativa dos resultados.
-

Modelo Baseline: TF-IDF + Regressão Logística

O modelo baseline foi construído utilizando a vetorização TF-IDF, seguida de um classificador de Regressão Logística treinado diretamente com os dados do dataset. Esse modelo apresentou elevado desempenho global, com:

- **Accuracy $\approx 0,949$**
- **F1-score macro $\approx 0,806$**

Observou-se excelente desempenho na classe majoritária (positiva), com recall próximo de 1. Em contrapartida, o modelo apresentou baixo recall para a classe negativa, indicando dificuldade em identificar corretamente avaliações negativas. Esse comportamento é esperado em cenários com forte desbalanceamento entre classes, nos quais o modelo tende a favorecer a classe dominante.

LLM em Modo Zero-Shot (XLM-RoBERTa)

Na sequência, foi aplicado um modelo LLM pré-treinado para análise de sentimentos em modo zero-shot. Diferentemente do baseline, esse modelo não foi treinado nem ajustado com os dados do Buscapé, sendo utilizado exatamente como disponibilizado após o pré-treinamento em grandes corpora genéricas.

Os resultados obtidos foram:

- **Accuracy $\approx 0,847$**
- *Recall* significativamente superior para a classe negativa
- Redução da acurácia global em relação ao modelo supervisionado

Apesar da menor acurácia total, o modelo LLM demonstrou maior capacidade de compreensão semântica, sendo capaz de identificar corretamente avaliações negativas longas, contraditórias ou com críticas implícitas, casos nos quais o modelo baseline frequentemente falhou.

Comparação de desempenho entre os modelos

Modelo	Accuracy	Precision (macro)	Recall (macro)	F1-score (macro)
--------	----------	----------------------	-------------------	---------------------

Baseline TF-IDF + LogReg	0.9490	0.9376	0.7421	0.8058
LLM Zero-shot (Transformers)	0.8467	0.6660	0.8275	0.7011

Análise Qualitativa

A análise qualitativa das previsões revelou três cenários principais:

- **Baseline erra e LLM acerta (439 casos):** textos longos, com estrutura mista, ironia ou críticas implícitas;
- **LLM erra e baseline acerta (1.945 casos):** textos curtos, genéricos ou com pouco conteúdo semântico;
- **Ambos erram (312 casos):** textos ambíguos ou inconsistentes, de difícil interpretação inclusive para avaliação humana.

Essa análise evidencia que os modelos não erram pelos mesmos motivos, indicando uma complementaridade entre abordagens estatísticas e semânticas.

BERTimbau (Fine-tuning Supervisionado)

Além do modelo LLM em modo zero-shot, foi avaliado o desempenho do **BERTimbau (neuralmind/bert-base-portuguese-cased)**, um modelo BERT pré-treinado especificamente para a língua portuguesa, ajustado supervisionadamente para a tarefa de classificação de sentimentos.

Diferentemente do modelo zero-shot, o BERTimbau passou por um processo de *fine-tuning* utilizando dados rotulados do próprio dataset, permitindo que o modelo se adaptasse ao domínio específico das avaliações do Buscapé. Para isso, foi construída uma amostra balanceada contendo 10.000 avaliações, igualmente distribuídas entre as classes positiva e negativa, divididas em conjuntos de treino e teste.

Após o treinamento, o modelo apresentou os seguintes resultados:

- **Accuracy $\approx$ 0,874**
- **F1-score macro $\approx$ 0,87**

Métricas por classe:

Classe	Precision	Recall	F1-score	Suporte
Negativa (0)	0,91	0,83	0,87	1000
Positiva (1)	0,84	0,92	0,88	1000

As métricas indicam um desempenho equilibrado entre as classes, evidenciando melhora significativa na identificação de avaliações negativas em comparação ao baseline e ao LLM zero-shot. O desempenho do BERTimbau demonstra a importância do ajuste supervisionado aliado à adequação linguística do modelo ao português brasileiro.

Questão 2 – Retrieval-Augmented Generation (RAG)

Fluxo da Questão

O pipeline RAG foi estruturado a partir das seguintes etapas:

1. Criação de documentos textuais sintéticos;
2. Fragmentação dos documentos em chunks;
3. Indexação dos chunks utilizando TF-IDF;
4. Recuperação dos trechos mais relevantes por similaridade do cosseno;
5. Geração da resposta final com o modelo FLAN-T5, restrita ao contexto recuperado.

Arquivos Utilizados (Base de Conhecimento)

Para aplicação do RAG, foram criados três documentos sintéticos (tratados como “arquivos”) com conteúdo curto e objetivo, simulando uma base de conhecimento interna. A escolha por documentos sintéticos foi adotada para permitir controle do conteúdo, rastreabilidade do gabarito e avaliação direta do mecanismo de recuperação.

Os arquivos utilizados foram:

- **Arquivo 1 – POP: Instalação e Comissionamento de Eletroposto**

Documento com as etapas operacionais do POP (prospecção, vistoria, viabilidade, orçamento, aprovação, planejamento, instalação/testes, comissionamento e entrega), incluindo critérios de aceite.

- **Arquivo 2 – Política de Dados e LGPD para Telemetria**

Documento com orientações de governança e conformidade (base legal, minimização, finalidade, controle de acesso, retenção, responsabilidades), contextualizando uso de dados em telemetria.

- **Arquivo 3 – FAQ: NLP (TF-IDF vs LLM) e Métricas**

Documento com explicações sintéticas sobre diferenças entre modelos clássicos e LLMs e sobre métricas usuais (accuracy, precision, recall, f1, macro/weighted).

Esses três arquivos foram selecionados por representarem domínios distintos (procedimento operacional, compliance e conteúdo técnico de IA), o que ajuda a testar se o retriever identifica corretamente o documento relevante dependendo da pergunta.

Pipeline Proposto e Implementado

O pipeline RAG foi estruturado nas seguintes etapas:

1. **Preparação dos documentos:** os 3 arquivos foram carregados/armazenados como textos.
2. **Chunking (fragmentação):** cada documento foi dividido em chunks curtos, para aumentar a precisão na recuperação (recuperar apenas o trecho relevante, em vez do documento inteiro).
3. **Indexação (Retriever):** aplicação de TF-IDF para representar cada chunk como vetor esparsos.
4. **Recuperação:** cálculo da similaridade do cosseno entre a consulta e os chunks indexados; seleção dos Top-k mais relevantes.
5. **Geração (Generator):** uso do FLAN-T5-base para gerar a resposta final, restrita ao contexto recuperado (resposta baseada apenas nos chunks retornados).

Justificativa da Escolha do Pipeline

A escolha do pipeline **TF-IDF + cosine similarity** como *retriever* e **FLAN-T5-base** como *generator* foi motivada pelo tamanho reduzido da base documental, pela simplicidade e interpretabilidade do TF-IDF, pelo menor custo computacional e pela adequação do FLAN-T5 à tarefa de geração de texto.

Avaliação do Pipeline

A avaliação foi feita por métrica de **Hit@K**, verificando se o documento correto (ou chunk do documento correto) aparecia entre os Top-K recuperados para cada pergunta.

Os resultados obtidos foram:

- Hit@1 = 1.000
- Hit@2 = 1.000
- Hit@3 = 1.000

Esses resultados que para todas as consultas testadas, o mecanismo de recuperação retornou corretamente o trecho relevante já nas primeiras posições, permitindo que o gerador (FLAN-T5) produzisse respostas alinhadas ao conteúdo dos documentos.

4. Conclusões

Os resultados esperados nesta atividade foram plenamente atingidos. O modelo baseline (TF-IDF + Regressão Logística) apresentou desempenho quantitativo superior, confirmando sua eficácia em cenários com grande volume de dados rotulados e domínio bem definido, mesmo diante do desbalanceamento entre classes.

Os modelos baseados em LLMs, por sua vez, demonstraram vantagens qualitativas relevantes, especialmente na interpretação semântica de avaliações negativas complexas, textos longos ou com críticas implícitas. O experimento com o BERTimbau, ajustado supervisionadamente, evidenciou que o fine-tuning aliado à adequação linguística do modelo ao português brasileiro resulta em desempenho mais equilibrado e robusto.

De forma geral, os experimentos indicam que LLMs não substituem integralmente os modelos clássicos, mas atuam como ferramentas complementares,

oferecendo ganhos importantes em compreensão contextual, generalização semântica e robustez frente a textos mais complexos.

5. Próximos Passos

Como continuidade deste projeto, sugerem-se os seguintes aprimoramentos:

- Ampliação do fine-tuning de modelos LLM, como o BERTimbau, utilizando uma fração maior do dataset;
- Exploração de modelos ensemble, combinando decisões do baseline e dos LLMs para reduzir erros complementares;
- Substituição do TF-IDF por embeddings densos no pipeline RAG, visando escalabilidade para bases documentais maiores;
- Avaliação dos modelos em datasets menos desbalanceados, permitindo análise mais equilibrada das métricas;
- Expansão da tarefa para classificação multiclasse ou análise de sentimentos baseada em aspectos.