



Dataset ASSIN

AVALIÇÃO 2 – NLP

Victor Matheus



INTRODUÇÃO

O dataset ASSIN (Avaliação de Similaridade Semântica e Inferência Textual) é um corpus em português composto por pares de sentenças extraídas de notícias do Brasil e de Portugal. Cada par contém:

- um score de similaridade (1 a 5), indicando o quanto as frases se relacionam;
- uma classificação de entailment:
 - 0 – none (sem relação)
 - 1 – entailment (uma frase implica a outra)
 - 2 – paraphrase (sentenças equivalentes)

O dataset possui classes desbalanceadas e sentenças curtas de domínio jornalístico, tornando-o ideal para estudar pré-processamento, extração de atributos e classificação em tarefas de NLP.


```
===== EXEMPLO DE PRÉ-PROCESSAMENTO (PAR DE FRASES) =====
```

```
Premise original (10):
```

```
O caminho de ajuste via aumento de carga tributária é muito mal visto pela sociedade e pelo Congresso.
```

```
Hypothesis original:
```

```
O aumento da carga tributária também não é visto com bons olhos pelo congresso.
```



EXEMPLO VISUAL DO PRÉ-PROCESSAMENTO (PAR DE FRASES)

===== EXEMPLO DE PRÉ-PROCESSAMENTO (PAR DE FRASES) =====

Premise original (10):

O caminho de ajuste via aumento de carga tributária é muito mal visto pela sociedade e pelo Congresso.

Hypothesis original:

O aumento da carga tributária também não é visto com bons olhos pelo congresso.

Premise após pré-processamento:

caminho ajuste via aumento carga tributária mal visto sociedade congresso

Hypothesis após pré-processamento:

aumento carga tributária visto bons olhos congresso

=====

CONTEXTO DA AVI

- Pipeline clássico de NLP
- Pré-processamento
- Múltiplas extrações de atributos
- Classificação com Regressão Logística
- Melhor caso (baseline):
 - Acurácia $\approx 0,78$
 - Macro-F1 $\approx 0,32$

Destaque:

- Acurácia sozinha não é suficiente
- Apesar da boa acurácia, o Macro-F1 foi baixo.
- Isso indica viés para a classe majoritária.



AV2 — CLASSIFICAÇÃO COM LLM E RETRIEVAL-AUGMENTED GENERATION (RAG)

- A apresentação foca na AV2, que expande o trabalho da AV1.
- O objetivo foi comparar um classificador tradicional com uma LLM e implementar múltiplos pipelines de RAG.
- Cada exemplo tem uma premissa e uma hipótese.
- Dataset desbalanceado
- O modelo precisa decidir se há inferência, equivalência ou nenhuma relação.
- Esse problema é difícil porque muitas inferências são implícitas.

Por que ir além da AV1?

- Modelos tradicionais sofrem com desbalanceamento
- LLMs capturam semântica melhor
- RAG reduz alucinações
- Comparar abordagens clássicas vs modernas



QUESTÃO 1 (AV2): BASELINE VS LLM

Baseline AV1 (Regressão Logística) ✕ LLM local gratuita (phi3.5 – Ollama)

Objetivo principal

Avaliar diferenças quantitativas e qualitativas entre abordagens tradicionais e LLMs.

Baseline AV1

- Regressão Logística
- Atributos estatísticos simples:
 - número de palavras
 - soma do tamanho das palavras
- Classe alvo: entailment_judgment



LLM utilizada

- Modelo: phi3.5
- Execução: local (Ollama)
- Sem uso de API paga ou chave externa

Função da LLM

- Receber par de sentenças
- Retornar classe: 0, 1 ou 2


PROCESSO IMPLEMENTADO

- 1. Seleção de subconjunto do dataset
- 2. Envio de premise + hypothesis no prompt
- 3. Geração de classe pela LLM
- 4. Comparação com rótulo real
- 5. Cálculo de métricas

Modelo	Amostras	Acurácia	Macro-F1
Baseline AV1	750	0,7787	0,3193
LLM (phi3.5)	150	0,7800	0,3908

Embora a acurácia seja praticamente igual, o Macro-F1 da LLM é superior, indicando melhor equilíbrio entre classes.

No código, cada par de sentenças é enviado à LLM, que retorna uma classe. Em seguida, comparei a predição com o rótulo real e calculei as métricas tradicionais.



ANÁLISE POR CLASSE

Baseline AV1

- Classe 0 (none): recall ≈ 1.0
- Classe 1 (entailment): recall ≈ 0.04
- Classe 2 (paraphrase): recall = 0.0



LLM (phi3.5)

- Classe 0 (none): recall ≈ 0.96
- Classe 1 (entailment): recall ≈ 0.19
- Classe 2 (paraphrase): recall = 0.0

O modelo praticamente sempre escolhe a classe none. Isso explica a alta acurácia e o baixo Macro-F1.

A LLM ainda sofre com paraphrase, mas apresenta melhora clara no reconhecimento de entailment, o que impacta diretamente o Macro-F1.



CONCLUSÃO — QUESTÃO 1

Síntese dos resultados

- O baseline da AV1 e a LLM apresentaram acurácias praticamente equivalentes
- A LLM obteve Macro-F1 superior, indicando melhor equilíbrio entre classes
- Ambos os modelos apresentaram dificuldade na classe paraphrase

Análise crítica

- O modelo tradicional:
 - apresenta forte viés para a classe majoritária (none)
 - alcança alta acurácia mesmo com baixo desempenho em classes minoritárias
- A LLM:
 - demonstra melhor compreensão semântica
 - reconhece inferências implícitas com maior frequência
 - ainda tende a ser conservadora em cenários ambíguos

QUESTÃO 2 (AV2): PIPELINE RAG

Pipeline geral:

1. Documentos
2. Chunking
3. Indexação
4. Recuperação Top-k
5. Geração com LLM
6. Avaliação

DOCUMENTOS UTILIZADOS (RAG)

- doc1_assin.txt — dataset ASSIN
- doc2_av1_pipeline.txt — resultados da AV1
- doc3_rag_conceitos.txt — conceitos de RAG



PIPELINES RAG

RAG-1 (Baseline):

- Chunking fixo
- TF-IDF
- Top-k = 3
- LLM phi3.5

Accuracy proxy: 1.0

Observações:

- Esse foi o pipeline original.
- Funcionou muito bem para esse conjunto pequeno.

RAG-2 (Chunking por Sentença):

- Chunking por sentença
- TF-IDF
- Top-k = 3

Accuracy proxy: 0,33

Observações:

- Aqui o texto ficou fragmentado demais.
- O contexto se perdeu.

RAG-3 (Recuperação Híbrida):

- Chunking fixo
- TF-IDF + reforço lexical
- Recuperação híbrida

Accuracy proxy: 0,33

Observações:

- A heurística adicional não trouxe ganho.
- TF-IDF simples já era suficiente.

PERGUNTAS, DOCUMENTOS RECUPERADOS E RESPOSTAS

Pergunta 1:

Quais são as classes do entailment_judgment e o que cada uma significa?

Documentos recuperados:

- doc1_assin.txt
- doc2_av1_pipeline.txt
- doc1_assin.txt

Resposta gerada:

0 = none, significando nenhuma relação de inferência ou equivalência;

1 = entailment, onde a premissa implica a hipótese;

2 = paraphrase, indicando sentenças semanticamente equivalentes.

Avaliação: CORRETA

Pergunta 2:

Qual coluna do ASSIN representa a similaridade semântica e qual é o intervalo dela?

Documentos recuperados:

- doc1_assin.txt
- doc1_assin.txt
- doc1_assin.txt

Resposta gerada:

relatedness_score, com um intervalo de 1 a 5.

Avaliação: CORRETA

PERGUNTAS, DOCUMENTOS RECUPERADOS E RESPOSTAS

Pergunta 3:

Quais técnicas de extração de atributos foram testadas na AV1?

Documentos recuperados:

- doc2_av1_pipeline.txt
- doc1_assin.txt
- doc1_assin.txt

Resposta gerada:

CountVectorizer, TF-IDF, coocorrência, Word2Vec e atributos estatísticos.

Avaliação: CORRETA

Pergunta 4:

Qual foi o melhor caso da AV1 em termos de acurácia e qual métrica ficou baixa por desbalanceamento?


Documentos recuperados:

- doc2_av1_pipeline.txt
- doc2_av1_pipeline.txt
- doc2_av1_pipeline.txt

Resposta gerada:

A abordagem estatística atingiu aproximadamente 0,7787 de acurácia. O macro-F1 foi a métrica que ficou baixo devido ao desbalanceamento entre as classes.

Avaliação: CORRETA



CONCLUSÃO GERAL DA AV2

Conclusões do Projeto AV2

- A LLM apresentou Macro-F1 superior ao baseline tradicional
- Acurácia isolada não reflete desempenho real em datasets desbalanceados
- O pipeline RAG funcionou corretamente e sem alucinações
- O pipeline baseline foi o mais adequado para este cenário
- Qualidade e estrutura dos documentos impactam diretamente o RAG

A AV2 mostrou que tanto LLMs quanto RAG agregam valor, mas apenas quando usados de forma adequada ao problema. O trabalho reforça a importância da análise crítica na escolha de modelos e pipelines.

O objetivo não foi maximizar métricas, mas entender o comportamento de diferentes abordagens em tarefas de inferência textual.



Dataset ASSIN

OBRIGADO

Victor Matheus

