



Detecção de Discurso de Ódio com LLMs e RAG



Overview



01 Introdução

02 Questão 1 - Comparação Inicial

03 Impacto da configuração (Timeout)

04 Discussão da Questão 1

05 Questão 2 - Base de conhecimento (RAG)

06 Metodologia dos Experimentos

07 Análise dos Resultados

08 Porquê dos Extremos

09 Conclusão

10 Obrigado!

Introdução

- Dataset: Brazilian Portuguese Hatespeech dataset;
- Desafio: Gírias, ironia e referências históricas camufladas;
- Papel do RAG: Atuar como um “cérebro externo” para evitar alucinações da IA;
- Por que RAG: LLMs não conhecem as leis brasileiras ou casos específicos sem auxílio;

text	hatespeech_comb	hatespeech_G1	annotator_G1	hatespeech_G2	annotator_G2	hatespeech_G3	annotator_G3
@_andrea_b O cara vive em outro mundo Não no mundo real REFUGIADOS são os que vivem Nas favelas vizinhas as suas fortalezas	1	1A		1V		0E	
@_carmeloneto Estes incompetentes não cuidam nem do povo brasileiro e nem dos poucos refugiados que aqui estão.	0	1D		0V		0C	
@_carmeloneto Os 'cumpañero' quebraram todas as regras.	0	1A		0B		0E	
@_GlitteryKisses é isso não conseguem pensar no sentido lato para além do que se vê a frente dos olhos	0	0C		0V		0D	
@_igljra bom dia macaco branco haha	1	0A		1I		1E	
@_Joen imagino... ow mandei fazer um body opressor pra Duda! hahahaha	0	0B		0V		0C	
@_Joen parabéns brou! Menina é bom demais!	0	0E		0B		0C	
@_Joen PARABÉNS IRMÃO, SAÚDE E #PAZ. AMÉM.	0	0B		0Dani		0A	
@_jujuba_lima Ah, convivendo apenas comigo esse fds... Precisava disso... Pensando em mtas coisas e trabalhando no meio disso rs.	0	0A		0I		0A	
@_jujuba_lima E o sono... rs. Cheiros. Tb adorei!	0	0C		0B		0C	
@_jujuba_lima Qww. linda.. trabalho amanhã =/ dó	0	0B		0It		0C	
@_jujuba_lima que baummm hein, tem coisa mais gostosa? Eu ando reflexiva.. mas, enmm paz. Tb mto bom!	0	0A		0It		0B	
@_jujuba_lima SO nada, faço o básico hahaha	0	0D		0It		0B	
@_jujuba_lima Taí, sou ótima com sobremesas, doces, bolos...	0	0A		0I		0E	
@_kcris Não deixe as lembranças e saudades te minarem. Enfrente, ouça músicas.. (Essa é linda msm). Conhece The Corrs?	0	0A		0S		0C	
@_kcris QUyndo a música Preciso de vc.. Excelente, linda! Foda, pq tô separando. PQP...	0	1A		0It		0E	
@_latinlover cedemos ao encanto e caímos de boca meu caro!	0	0E		0B		0D	
@_latinlover Perfume pra mão jovem amante.....pra mão. Cappice?	1	1D		1It		0E	
@_Nabarra 'Estimo que se foda' será mais profissional.	1	1D		0B		1B	
@_NandaSilva bom dia sapatao da minha vida	1	1A		1Dani		1C	
@_opressor falei isso desde ontem ..kkkk https://t.co/UYW7iJ33	0	1A		0Dani		0C	
@_SsarahA @Ebandeira_ isso n ta errado, mas épesquisa de gente burra, a mulher trabalha menos que o homem	1	1B		1I		1B	
@_TheEarlyBird @JOAQUINVOLTQU e que tal uma linha de bonés?? https://t.co/iHrd5qTIH6	0	0A		0It		0A	
[9/3 09:11] jhu : Bom viado mais lindo							
[9/3 09:11] Df Luizinho: Bom dia sapatão mais gostosa	1	1A		1It		0D	

Questão 1 - Comparação Inicial

- Modelos: Llama 3 (8B), Gemma 2 (9B), Regressão Logística (Baseline AV1);
- Resultados Iniciais: Acurácia reduzida no Gemma devido a interrupções;
- Observação: O baseline (AV1) é rápido, mas ignora nuances semânticas;

```
Model: PRED_AV1  
Acc: 0.7333 | F1: 0.6522
```

```
Model: PRED_LLAMA3  
Acc: 0.6833 | F1: 0.6545
```


```
Model: PRED_GEMMA2  
Acc: 0.7667 | F1: 0.7879
```

```
Model: PRED_AV1  
Acc: 0.7333 | F1: 0.6522
```

```
Model: PRED_LLAMA3  
Acc: 0.6833 | F1: 0.6667
```

```
Model: PRED_GEMMA2  
Acc: 0.7833 | F1: 0.8000
```

Impacto da configuração (Timeout)



- 01 O Gargalo: Inferência de modelos 8B/9B exige tempo para processar o Grafo de Atenção;
- 02 Causa: No timeout de 30s, o Gemma2 cortava o raciocínio, resultando em classificações nulas;
- 03 Efeito: Aumentar para 60s permitiu ao modelo analisar o tweet inteiro e o contexto;
- 04 Resumindo: Parâmetros de infraestrutura impactam diretamente a métrica de negócio (acurácia);

Discussão da Questão 1

```
Model: PRED_AV1  
Acc: 0.7333 | F1: 0.6522
```

```
Model: PRED_LLAMA3  
Acc: 0.6833 | F1: 0.6667
```

```
Model: PRED_GEMMA2  
Acc: 0.7833 | F1: 0.8000
```

- ▶ **Vencedor:** Gemma 2 com Acurácia de 0.78 e F1-Score de 0.80
- ▶ **Llama 3:** Alta sensibilidade, porém gerou mais falsos positivos;
- ▶ **Casos Críticos:** Tweets com palavras “mas” foram melhor interpretados pelo Gemma 2;
- ▶ **Conclusão:** LLMs superaram o baseline da AV1 ao entender a intenção por trás das palavras.

CONSTITUIÇÃO FEDERAL E LEGISLAÇÃO SOBRE DISCURSO DE ÓDIO NO BRASIL

1. LEI Nº 7.716/1989 (Lei do Racismo): Define crimes resultantes de preconceito de raça ou de cor.
Art. 20. Praticar, induzir ou incitar a discriminação ou preconceito de raça, cor, etnia, religião ou procedência nacional. Pena: reclusão de um a três anos e multa.

2. LEI Nº 14.532/2023 (Injúria Racial): A injúria racial agora é tipificada como crime de racismo.
A ofensa à dignidade de alguém baseada em raça, cor, etnia ou procedência nacional é imprescritível e inafiançável.

3. APOLOGIA AO CRIME (Art. 287 do Código Penal): Fazer, publicamente, apologia de fato criminoso ou de autor de crime.
Isso inclui postagens que celebram criminosos condenados ou atos de violência explícita, como feminicídio ou terrorismo.

4. MISOGINIA E DISCURSO DE ÓDIO CONTRA MULHERES: O STF entende que a liberdade de expressão não protege discursos que incitam a violência contra a mulher ou que promovem a inferiorização de gênero.

CONTEXTO DE REFERÊNCIAS CULTURAIS E CASOS CRIMINAIS BRASILEIROS

1. CASO ELIZA SAMUDIO: Eliza Samudio foi assassinada em 2010. Referências ao seu corpo ou ao crime são frequentemente usadas em redes sociais como forma de "piada" misógina ou apologia ao crime. Menções como "achar o corpo da Eliza" são classificadas como discurso de ódio/tóxico (Label 1).

2. USO PEJORATIVO DE TERMOS RELIGIOSOS: O uso do termo "burca" ou "terrorista" para atacar mulheres ou refugiados muçulmanos configura preconceito religioso e xenofobia. O contexto deve avaliar se o tweet está atacando a liberdade de vestimenta ou associando a religião a atos violentos.

3. SARCASMO POLÍTICO E RADICALIZAÇÃO: Frases que utilizam o nome de figuras políticas para incitar violência contra grupos opostos ou minorias devem ser tratadas como discurso de ódio. A polarização muitas vezes esconde ofensas diretas sob nomes de políticos.

4. TERMOS LGBTQIAPN+: O uso de gírias como "sapata" ou "raça" em tom generalista e agressivo é identificado como discriminação por orientação sexual.

DICIONÁRIO DE TERMOS CODIFICADOS E GÍRIAS DE ÓDIO (EVASÃO DE FILTROS)

1. CÓDIGOS NUMÉRICOS: O número "1488" é um código neonazista. O "14" refere-se às 'Fourteen Words' e "88" à saudação 'Heil Hitler' (H sendo a 8ª letra do alfabeto).

2. CÓDIGOS DE FRUTAS E ALIMENTOS: Em fóruns extremistas, usuários usam nomes de frutas ou objetos para se referir a minorias, tentando evitar a detecção por algoritmos de palavras-chave simples. Exemplo: usar "suco" para se referir a algo tóxico ou "limpeza" para eugenia.

3. SIGLAS DE GRUPOS: Termos como 'PNR' ou associações com movimentos ultranacionalistas radicais indicam viés de intolerância política e racial quando usados para atacar a soberania de outros grupos ou imigrantes.

4. TERMOS DE DESUMANIZAÇÃO: Chamar grupos de pessoas de "pragas", "parasitas" ou "lixo" é uma técnica clássica de discurso de ódio para justificar a violência, sendo um forte indicativo de Label 1.

Questão 2 - Base de conhecimento (RAG)

- **Documento Jurídico:** Base legal para fundamentar o que é crime ou injúria.
- **Documento Histórico:** Casos reais (ex: Eliza Samudio) para evitar erros de contexto.
- **Documento Glossário:** Decodificador de gírias e códigos de evasão.

Metodologia dos Experimentos

Configurações escolhidas:

01

Estratégia:

Testar 5 variações para achar o equilíbrio entre velocidade e precisão



EXPERIMENTO	Combinação	Banco	Recuperação
01	Fixed + paraphrase-multilingual-MiniLM-L12-v2	ChromaDB	Top-K
02	Sentence + all-MiniLM-L6-v2	Qdrant	MMR
03	Recursive + distiluse-base-multilingual-cased-v1	ChromaDB	Hybrid (BM25+Vec)
04	Sliding + paraphrase-MiniLM-L3-v2	Qdrant	Context-Compressed
05	Semantic + all-distilroberta-v1	Qdrant	Multi-Query

Análise dos Resultados

- Melhor Resultado: Experimento 5 (Precisão de 0.90 / Latência 1.5s).
- Pior Resultado: Experimento 1 (Precisão de 0.70 / Latência 36.4s).
- Consumo de RAM: Estável entre os modelos, com pico no modelo Multilingual (Exp 1).
- Escalabilidade: Qdrant provou ser o motor ideal para processamento em tempo real.

EXPERIMENTO	LATÊNCIA (S)	CUSTO RAM (MB)	PRECISÃO RECUP	RELEVÂNCIA (LLM)
1	36405	3.353	7	Média
2	12376	6.423	75	Média
3	35431	17.115	8	Média
4	1508	0	85	Alta
5	1507	0	9	Alta

01

Vantagem do Exp 5: Semantic Chunking não quebra o sentido das frases e Multi-Query amplia o alcance da busca.

02

Falha do Exp 1: O corte Fixed é aleatório; ele separa o "não" do "é crime", confundindo a IA.

03

O Fator Qdrant: A indexação por grafos (HNSW) foi a responsável pela queda de 95% no tempo de espera.

Porquê dos Extremos



01

A Questão 1 provou que LLMs são inteligentes, mas a Questão 2 provou que elas precisam de fundamentos para serem seguras (RAG).

02

O sucesso do sistema não veio de usar a "maior" IA, mas de escolher o melhor Banco (Qdrant) e a melhor busca (Multi-Query).

03

A arquitetura ideal para monitorar ódio online exige Contexto Semântico (RAG) aliado a uma Infraestrutura Ágil (Docker/Qdrant).

Conclusão





UFC



Obrigado!

