6º SEMESTRE

Processamento e linguagens naturais

Alekyne Ribeiro

Hugging Face Transformers

Usabilidade

- Hugging Face Transformers é uma biblioteca que suporta vários modelos pré-treinados(GPT, BERT, BART, T5, etc.) que foram ajustados para trabalhar com a língua portuguesa.

- Fácil Integração, O framework permite carregar e aplicar modelos com poucas linhas de código

Sigla (Tag)	Significado	Descrição
Propn	Nome proprio	Nomes especificos
Verb	Verbo	ação estado
Aux	Auxiliar	Acompanha verb princip.
DET	Determinante	introduz um subst
Noun	Substantivo	pessoa lugar coisa
Adp	Preposição	relação de subs + palavra
Num	Numeral	Quantidade

Erros ortográficos

Texto original

No meu café da manhã, tinha sobre a **meza**, **quejo**, **prezunto**, **mortandela**, **matega**, **saucinha** e iogurte natural. Mas o café estava sem **asúcar** e eu **presizo** de uma colher para mecher o café. Era tanta coisa que não sobrava **espaso** na meza. Liguei a televisam e estava paçando o “Bom Dia São Paulo”, onde mostrou como se constrói o espaso geográfico. Os home construimdo nos morros, as caza de simento e madera."

Texto normalizado

No meu café da manhã tinha sobre a Meca cacho pregunto mortadela macega sapucainha e iogurte natural Mas o café estava sem aguçar e eu preciso de uma colher para meche o café Era tanta coisa que não sobrava esparso na Meca Liguei a televisa e estava caçando o “ bom dia são Paulo ” onde mostrou como se constrói o esparso geográfico Os Home construindo nos morros as aza de saimento e madeira

enelvo

```
norm = Normaliser(tokenizer='readable',
resp = norm.normalise(text)
print(resp)
```

Codigo

```python
# b) Tokenize o texto
nlp = spacy.load('pt_core_news_sm')
doc = nlp(resp)

for token in doc:
    print(token.text)
```

Saida

```
No
meu
café
da
manhã
tinha
sobre
a
Meca
cacho
pregunto
mortadela
macega
sapucainha
e
iogurte
natural
Mas
o
café
estava
sem
aguçar
```

Faça uma tabela mostrando 3 colunas para todos os tokens: token , stemming e lematização.

	Token	Stemming	Lematização
0	café	café	café
1	manhã	manhã	manhã
2	sobre	sobr	sobre
3	Meca	mec	Meca
4	cacho	cach	cacho
5	pregunto	pregunt	pregunto
6	mortadela	mortadel	mortadela
7	macega	maceg	macega
8	sapucainha	sapuc	sapucainha